

Resumen— Se evalúa AP-9, una plataforma de análisis de ciclo de vida para estimar la huella de carbono de gemelos digitales agrícolas en las capas de sensores IoT, Edge y Cloud. Se ejecutó una simulación reproducible con semilla 42, 30 sensores, 10 ha y un horizonte de tres años. Las arquitecturas Cloud-heavy, híbrida y Edge-heavy generaron 1665,68; 852,03; y 626,25 kg CO₂e, respectivamente; la variante Edge-heavy alimentada con energía solar alcanzó 547,41 kg CO₂e, una reducción de 67,14 % frente a Cloud-heavy. Con 2500 registros sintéticos, XGBoost obtuvo el menor RMSE medio de validación cruzada ($2602,38 \pm 838,19$ kg CO₂e); Stacking no difirió significativamente de XGBoost. Los resultados cumplen el criterio operativo de reducción de 40 % bajo los supuestos deterministas del motor y muestran el predominio de la carga Cloud en el impacto operativo.

Palabras clave: análisis de ciclo de vida, agricultura de precisión, computación Edge, gemelos digitales, huella de carbono.

Abstract— This work evaluates AP-9, a life-cycle assessment platform that estimates the carbon footprint of agricultural digital twins across IoT sensor, Edge and Cloud layers. A reproducible simulation using seed 42, 30 sensors, 10 ha and a three-year horizon was executed. Cloud-heavy, hybrid and Edge-heavy architectures produced 1665.68, 852.03 and 626.25 kg CO₂e, respectively; solar-powered Edge-heavy reached 547.41 kg CO₂e, a 67.14 % reduction versus Cloud-heavy. With 2500 synthetic records, XGBoost achieved the lowest mean cross-validation RMSE (2602.38 ± 838.19 kg CO₂e); Stacking did not differ significantly from XGBoost. The results meet the operational 40 % reduction criterion under deterministic engine assumptions and show that Cloud workload dominates operational impact.

Keywords: carbon footprint, digital twins, Edge computing, life-cycle assessment, precision agriculture.

1 INTRODUCCIÓN

Los gemelos digitales agrícolas integran sensores, comunicaciones, procesamiento local y servicios Cloud para representar una parcela y apoyar decisiones de riego, fertilización o cosecha [18]. Esta infraestructura puede mejorar la disponibilidad de información, pero también incorpora emisiones de fabricación, transporte, operación y fin de vida. Por ello, una evaluación ambiental no debe limitarse a la electricidad consumida durante el uso [1], [2].

Aunque existen métodos ascendentes para estimar la huella de dispositivos IoT y estudios que relacionan digitalización y análisis de ciclo de vida [1]–[3], [7], [11]–[17], persiste una brecha: faltan evaluaciones reproducibles que comparen, bajo una misma carga funcional, cómo la distribución del cómputo entre Edge y Cloud modifica la huella de un gemelo digital agrícola. La contribución de este

trabajo es AP-9, un artefacto de software que integra un inventario explícito por capa, un motor parametrizable de ACV y un módulo predictivo para explorar configuraciones antes del despliegue.

El estudio diferencia tres aportes: (i) una comparación determinista de cuatro arquitecturas funcionalmente equivalentes; (ii) un desglose de impacto por etapa y capa que permite identificar decisiones de diseño sensibles; y (iii) una evaluación de modelos de aprendizaje automático sobre un conjunto sintético generado por reglas del motor. No se afirma que el modelo predictivo valide un fenómeno agrícola independiente: evalúa su capacidad de aproximar el generador implementado.

Se plantean tres preguntas de investigación: RQ1: ¿una arquitectura Edge-heavy reduce al menos 40 % la huella total frente a Cloud-heavy, manteniendo el inventario de sensores, área y horizonte temporal? RQ2: ¿qué etapas y parámetros

concentran el impacto en los escenarios simulados? RQ3: ¿qué modelo estima con menor error la huella generada por AP-9? La hipótesis H1, definida antes de la ejecución, establece que Edge-heavy reducirá al menos 40 % respecto a Cloud-heavy. Estas preguntas se responden mediante simulación reproducible; sus conclusiones se limitan a los supuestos y factores configurados.

El resto del artículo describe el método experimental y el motor de ACV, presenta los resultados por arquitectura y por

2.1 Enfoque y alcance del estudio

Este trabajo es una investigación aplicada de desarrollo y evaluación de software mediante simulación. Se creó el proyecto experimental EXP-AP9-42 y se fijó la semilla aleatoria 42. Se compararon cuatro configuraciones con 30 sensores, 10 ha y un horizonte de tres años: Cloud-heavy, híbrida, Edge-heavy sin energía solar y Edge-heavy con energía solar. Todas conservaron el inventario de sensores, el área, el horizonte temporal y el servicio funcional del gemelo; solo variaron la asignación de recursos Edge/Cloud y la alimentación de los nodos locales. Esta configuración es un caso de estudio y no representa todos los despliegues agrícolas.

2.2 Arquitectura tecnológica del sistema AP-9

AP-9 se organiza en una interfaz de configuración, una API que ejecuta el motor de ACV y el pipeline predictivo, y una capa de persistencia para inventarios, factores, escenarios y resultados. La implementación separa los módulos de cálculo, simulación y visualización para que cada escenario pueda volver a ejecutarse con los mismos parámetros y semilla. Esta separación es coherente con el procesamiento distribuido Edge-Cloud [4], [7].

La comparabilidad se asegura manteniendo constante la funcionalidad evaluada: monitorización de 10 ha durante tres años con el mismo inventario de sensorización. No se comparan beneficios agronómicos, rendimiento del cultivo ni emisiones directas de fertilización, riego o metano; el límite del sistema corresponde a la infraestructura digital que soporta el gemelo.

2.3 Motor de análisis de ciclo de vida (LCA)

El objetivo del ACV es comparar la huella de carbono de alternativas de infraestructura digital para una unidad funcional definida como la monitorización de 10 ha durante tres años. Los límites incluyen fabricación, transporte, instalación, operación y fin de vida de sensores, nodos Edge y recursos Cloud asignados al servicio. El cálculo sigue una estructura compatible con las fases de objetivo y alcance, inventario, evaluación de impacto e interpretación de ISO 14040 e ISO 14044 [8], [9], y con prácticas de contabilidad de gases de efecto invernadero [10], sin afirmar una certificación ISO. Para cada componente se calcula $E_{total} = E_{fabricación}$

modelo predictivo, discute las amenazas a la validez y delimita el alcance de las conclusiones.

2 METODOLOGÍA

+ $E_{transporte}$ + $E_{instalación}$ + $E_{operación}$ + $E_{fin_de_vida}$. La Tabla 1 muestra los factores por defecto; deben mantenerse trazables a su fuente y fecha de consulta en la versión de envío.

Tabla 1. Factores por defecto empleados en el motor de ACV de AP-9

Categoría	Valor	Unidad
Red eléctrica	0,150	kgCO2e/kWh
Red solar local	0,025	kgCO2e/kWh
Sensor compacto (fab.)	4,85	kgCO2e/ud.
Sensor óptico (fab.)	12,40	kgCO2e/ud.
Edge Raspberry-class (fab.)	18,50	kgCO2e/ud.
Edge Jetson/acelerador (fab.)	38,20	kgCO2e/ud.
Gateway industrial (fab.)	29,80	kgCO2e/ud.
Cómputo Cloud estándar	0,0032	kgCO2e/vCPU-h
Cómputo Cloud renovable	0,0006	kgCO2e/vCPU-h
Almacenamiento Cloud	0,85	kgCO2e/TB-mes
Transporte terrestre	0,125	kgCO2e/t-km
Crédito reciclaje WEEE	-1,80	kgCO2e/kg

La operación Edge utiliza el factor de red o el factor solar configurado. En Cloud, el motor separa cómputo, almacenamiento y transferencia de datos; los recursos compartidos se prorratan según la asignación del escenario. El crédito WEEE se aplica una sola vez al componente dispuesto al fin de vida y no se combina con otro crédito de reciclaje. La validación manual de los tres casos de control presentó una diferencia fija de 25,50 kg CO2e, atribuida al componente fijo de red dedicada incluido por el motor; esta

diferencia se declara para evitar interpretar la validación como coincidencia exacta.

2.4 Generación del conjunto de datos agronómico y modelado causal

Para evaluar el módulo predictivo se generaron 2500 instancias sintéticas con semilla 42 a partir de las variables de la Tabla 2. El generador toma rangos de configuración de sensores, Edge, Cloud, transmisión, resolución y duración, y aplica relaciones programadas del motor. Por tanto, estos datos no constituyen observaciones de campo ni se emplean para validar emisiones reales; permiten medir la fidelidad con que cada modelo aproxima el comportamiento del simulador. La generación sintética se declara explícitamente ante la escasez de datos operativos comparables y no sustituye una validación externa [5].

Tabla 2. Variables predictoras del conjunto de datos sintético

Variable	Rango	Descripción
sensor_count	2 – 50	Nodos IoT en campo
edge_count	1 – 10	Gateways locales
cloud_region_intensity	0,05 – 0,90	kgCO2e/kWh de la red del datacenter
data_volume_gb_daily	0,1 – 100,0	Volumen diario (exponencial, λ=15)
transmission_freq_hz	0,001 – 10,0	Frec. de sincronización IoT
model_resolution	0,1 – 1,0	Detalle poligonal del modelo 3D
crop_type	5 clases	trigo, maíz, soja, arroz, tomate
operation_days	30 – 365	Duración del ciclo de monitoreo
solar_powered	0 / 1	Autoconsumo solar en Edge

La variable objetivo total_co2e_kg corresponde a la salida del motor bajo los límites de infraestructura digital descritos. El tipo de cultivo se utiliza únicamente como un perfil sintético de carga del gemelo y no incorpora emisiones agronómicas directas de metano, fertilización o rendimiento. Se añadió una perturbación gaussiana controlada para probar la robustez del aprendizaje. Las distribuciones, rangos, fórmula exacta y dependencias del generador deben publicarse junto con la semilla y el archivo de configuración para permitir la réplica independiente.

2.5. Pipeline de aprendizaje automático y validación estadística

Se evaluaron Random Forest, XGBoost y SVR, además de Stacking y Blending contruidos a partir de los modelos base. El preprocesamiento usa un ColumnTransformer con estandarización de variables numéricas y codificación one-hot de cultivo. La partición fue 80/20 (2000/500 registros), estratificada solo por la semilla 42; el conjunto de prueba permaneció reservado. La selección de hiperparámetros se realizó mediante RandomizedSearchCV de cinco folds sobre entrenamiento y la evaluación final empleó diez folds. Los hiperparámetros seleccionados, versiones, commit y comandos se incluyen en el Apéndice A y en el material suplementario.

El rendimiento se informa mediante RMSE y R² en una prueba independiente y mediante validación cruzada de diez folds en el conjunto de entrenamiento. Se aplicaron Friedman como prueba global, Wilcoxon pareado para comparaciones planificadas, la corrección de varianza de Nadeau-Bengio para contrastar XGBoost y Stacking, bootstrap de 2000 réplicas para el RMSE y Shapiro-Wilk y Breusch-Pagan como diagnósticos de residuos. Las comparaciones Wilcoxon se interpretan con corrección de Holm; una diferencia no significativa no prueba equivalencia entre modelos.

3 RESULTADOS

3.1. Comparación de arquitecturas

Cloud-heavy produjo 1665,68 kg CO2e en el horizonte analizado. La arquitectura híbrida redujo la huella a 852,03 kg CO2e (48,85 %), Edge-heavy sin energía solar a 626,25 kg CO2e (62,40 %) y Edge-heavy con energía solar a 547,41 kg CO2e (67,14 %). Por tanto, el criterio operativo de H1 se cumplió en las dos configuraciones Edge-heavy bajo los supuestos deterministas del motor.

Tabla 3. Huella total según la arquitectura simulada

Escenario	Total kg CO2e	Reducción respecto a Cloud-heavy	kg CO2e/ha
Cloud-heavy	1665,68	0,00 %	166,57
Híbrida	852,03	48,85 %	85,20
Edge sin solar	626,25	62,40 %	62,63
Edge con solar	547,41	67,14 %	54,74

3.2. Desglose de ciclo de vida y sensibilidad

En Cloud-heavy, la operación concentró 1385,01 kg CO2e (83,1 % del total), impulsada principalmente por Cloud (1270,91 kg CO2e). Edge-heavy con energía solar elevó la

fabricación de 195,30 a 210,10 kg CO₂e, pero redujo la operación a 244,24 kg CO₂e. En el análisis de sensibilidad de la configuración híbrida, el número de sensores tuvo el mayor efecto máximo (25,11 %), seguido de vCPU Cloud (20,91 %) y horas diarias Cloud (19,74 %). El almacenamiento Cloud no superó 0,88 %.

3.3. Predicción de emisiones

Tabla 4. Desempeño predictivo de los modelos evaluados

Modelo	CV RMSE kg CO ₂ e	Prueba RMSE kg CO ₂ e	R ² prueba
Random Forest	4232,41 ± 1375,32	3749,67	0,80349
XGBoost	2602,38 ± 838,19	2338,61	0,92356
SVR	5902,08 ± 1756,40	4908,53	0,66326
Stacking	2659,57 ± 593,19	2212,89	0,93156
Blending	3708,63 ± 1363,09	2921,94	0,88068

XGBoost obtuvo el menor RMSE medio de validación cruzada, 2602,38 ± 838,19 kg CO₂e. En la prueba independiente, Stacking alcanzó el menor RMSE (2212,89 kg CO₂e) y el mayor R² (0,93156), pero no difirió significativamente de XGBoost (Wilcoxon p = 0,27832; Nadeau-Bengio p = 0,778202). Friedman detectó diferencias globales entre modelos ($\chi^2 = 35,92$; p < 0,001). En las comparaciones planificadas, XGBoost superó a Random Forest, SVR y Blending; los p ajustados por Holm fueron ≤ 0,00391. El IC bootstrap de su RMSE fue [1837,14; 2924,84] kg CO₂e. Los residuos no fueron normales y presentaron heterocedasticidad (p < 0,001); por ello, la inferencia se interpreta con cautela.

4 DISCUSIÓN

La comparación por arquitectura indica que la huella no se distribuye uniformemente entre las capas. En Cloud-heavy, el componente operativo de Cloud concentra la mayor parte del impacto; al desplazar procesamiento hacia Edge y utilizar alimentación solar local se reduce la operación, aunque aumenta moderadamente la fabricación. El hallazgo es consistente con la necesidad de considerar emisiones incorporadas y operativas en sistemas IoT [1], [2].

El análisis de sensibilidad determinista y la importancia por permutación no responden exactamente a la misma pregunta. El primero cuantifica cambios locales en el escenario híbrido y señala al número de sensores, vCPU

Cloud y horas diarias Cloud. La segunda describe qué variables ayudan al modelo a aproximar el generador sintético; volumen de datos, intensidad de carbono Cloud, días de operación y frecuencia de transmisión ocupan las primeras posiciones. Ninguno de los dos resultados debe interpretarse como causalidad observada en campo.

XGBoost obtuvo el menor RMSE medio en validación cruzada y fue seleccionado como modelo principal. Sin embargo, Stacking obtuvo el mejor resultado en la prueba independiente y no presentó diferencia estadísticamente significativa frente a XGBoost. Este resultado no demuestra equivalencia ni una superioridad absoluta de XGBoost; la selección responde al desempeño promedio y a una implementación más directa.

Las amenazas a la validez son cuatro. Interna: el resultado depende de factores configurados y de la comparabilidad funcional de escenarios; se mitiga fijando inventario, horizonte y semilla. De constructo: los factores de emisión son demostrativos y requieren trazabilidad externa. Externa: un único caso de 30 sensores, 10 ha y tres años no permite generalizar a otras explotaciones. De conclusión: los datos sintéticos y la no normalidad de residuos limitan la inferencia estadística. No se realizó Monte Carlo porque los factores no disponen de distribuciones de incertidumbre válidas; no se inventaron supuestos probabilísticos.

5 CONCLUSIONES

AP-9 permitió comparar de manera reproducible cuatro arquitecturas de gemelo digital agrícola dentro de límites de infraestructura digital. Edge-heavy sin energía solar redujo la huella total en 62,40 % y Edge-heavy con energía solar en 67,14 % frente a Cloud-heavy; ambas cumplen el umbral operativo de H1. La reducción se explica, en este caso de estudio, por la disminución de las emisiones operativas asociadas a Cloud.

XGBoost obtuvo el menor RMSE medio en validación cruzada, mientras que Stacking presentó el mejor desempeño en la prueba independiente. Dado que no hubo diferencia estadísticamente significativa entre ambos, no se declara un ganador absoluto. La evidencia es apropiada para evaluar el simulador y orientar configuraciones dentro de sus parámetros, pero no valida aún una predicción de emisiones agrícolas reales.

Como trabajo futuro se requiere contrastar el motor y los modelos con telemetría real, sustituir los factores demostrativos por factores trazables por fabricante o base de datos, publicar el entorno reproducible e incorporar distribuciones de incertidumbre para aplicar Monte Carlo.

DECLARACIONES

Ética, conflictos y financiación. El estudio no involucró

participantes humanos, datos personales ni experimentación con animales; por ello no requirió aprobación ética. Los autores deben confirmar antes del envío la declaración real de conflictos de interés y la fuente de financiación o su ausencia. Uso de IA generativa. Se utilizó una herramienta de IA generativa únicamente como apoyo de redacción y revisión lingüística. Los autores revisaron el manuscrito, verificaron los resultados numéricos y asumen la responsabilidad íntegra por su contenido. Esta declaración debe ajustarse si la herramienta se usó también para código, análisis o figuras. Disponibilidad de materiales. El paquete suplementario de evaluación acompaña este manuscrito e incluye el código de AP-9, scripts de ejecución, configuración de escenarios, dataset_sintetico_semilla42.csv, resultados CSV, figuras, hiperparámetros y metadatos de reproducibilidad. El identificador del commit evaluado es cefeeef88af6115fffc624a09eb375595d6a5b208. Antes de una publicación externa, los autores deberán depositar el mismo paquete en un repositorio público o anónimo con licencia explícita y añadir la URL persistente.

REFERENCIAS

- [1] P. La Rocca, G. Guennebaud, A. Bugeau, and A.-L. Ligozat, "Estimating the carbon footprint of digital agriculture deployment: A parametric bottom-up modeling approach," *J. Ind. Ecol.*, vol. 28, pp. 1–15, 2024, doi: 10.1111/jiec.13568.
- [2] T. Pirson and D. Bol, "Assessing the embodied carbon footprint of IoT edge devices with a bottom-up life-cycle approach," *J. Clean. Prod.*, vol. 322, p. 128966, 2021, doi: 10.1016/j.jclepro.2021.128966.
- [3] M. Pradel, M. de Fays, and C. Segueineau, "Comparative life cycle assessment of intra-row and inter-row weeding practices using autonomous robot systems in French vineyards," *Sci. Total Environ.*, vol. 838, p. 156441, 2022, doi: 10.1016/j.scitotenv.2022.156441.
- [4] S. A. Ahmed et al., "Edge AI for Smart Energy Systems: A Comprehensive Review," in *Edge Computing Applications*, IntechOpen, 2025, doi: 10.5772/intechopen.1224342.
- [5] MAIZX Consortium, "MAIZX: A Carbon-Aware Framework for Optimizing Cloud Computing Emissions," arXiv preprint arXiv:2506.19972, 2025.
- [6] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?," in *Adv. Neural Inf. Process. Syst. (NeurIPS), Datasets and Benchmarks Track*, vol. 35, pp. 507–520, 2022.
- [7] Modeling the Green Cloud Continuum: integrating energy considerations into Cloud-Edge models, *Cluster Computing*, Springer, 2024, doi: 10.1007/s10586-024-04383-w.
- [8] International Organization for Standardization, ISO 14040:2006 Environmental management – Life cycle assessment – Principles and framework. Geneva: ISO, 2006.
- [9] International Organization for Standardization, ISO 14044:2006 Environmental management – Life cycle assessment – Requirements and guidelines. Geneva: ISO, 2006.
- [10] Greenhouse Gas Protocol, A Corporate Accounting and Reporting Standard, rev. ed. World Resources Institute / World Business Council for Sustainable Development, 2015.
- [11] K. C. Adeyemi et al., "Digital twin-driven strategic demolition plan for circular asset management of bridge infrastructures," *PMC*, 2024. Available: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC11950195/>.
- [12] A. Arias, G. Feijoo, and M. T. Moreira, "Dynamic life cycle assessment in environmental assessment of processes and products: a scoping review of sectoral applications, digitalization, decision support, and policy relevance," *Environ. Impact Assess. Rev.*, vol. 121, p. 108552, 2026, doi: 10.1016/j.eiar.2026.108552.
- [13] D. B. Olawade, J. O. Ijiwade, A. Ojo, J. O. Alabi, B. D. Makanjuola, and O. Z. Wada, "Digital twin technology for environmental management: applications, benefits, and implementation challenges," *Environ. Pollut. Manag.*, vol. 3, pp. 418–435, 2026, doi: 10.1016/j.epm.2026.07.003.
- [14] R. Aiasrah, R. Wehbi, V. Ikalovic, A. Aljer, and M. Sadek, "Digital twins for building sustainability: a life cycle-oriented critical review," *Sustain. Cities Soc. Adv.*, vol. 2, art. 100091, 2026, doi: 10.1016/j.scsadv.2026.100091.
- [15] M. N. Shubairi, P. Furtado, and R. F. Carvalho, "Decision support systems for digital twins in aquaculture: a systematic literature review," *Aquac. Eng.*, vol. 114, art. 102728, 2026, doi: 10.1016/j.aquaeng.2026.102728.
- [16] F. Briatore, F. Chiacchio, N. Trapani, and L. M. Oliveri, "A bibliometric review for mapping synergies between life cycle assessment and industry 4.0 in the food sector," *Discover Food*, vol. 6, art. 102, 2026, doi: 10.1007/s44187-026-00837-9.
- [17] S. Toniolo, G. Pierli, L. Bravi, L. Liberatore, and F. Murmura, "Digital technologies and circularity: trade-offs in the development of life cycle assessment," *Int. J. Life Cycle Assess.*, vol. 30, no. 12, pp. 2537–2557, 2025, doi: 10.1007/s11367-025-02436-9.
- [18] K. Khaqan et al., "Exploring digital twins in agriculture with current applications and

implications for research, policy and practice," Discover Agriculture, vol. 4, p. 278, 2026, doi: 10.1007/s44279-026-00760-8.

APÉNDICE A MATERIAL SUPLEMENTARIO Y REPRODUCIBILIDAD

Este apéndice especifica los elementos necesarios para repetir el experimento y delimita el alcance de sus resultados. Los archivos señalados se entregan en el paquete suplementario resultados_experimento.

A.1 Entorno y procedimiento

Elemento	Configuración evaluada
Sistema operativo	Windows 10 10.0.26200 SP0
Semilla	42 en Python, NumPy, scikit-learn y XGBoost
Python	3.11.0
Node.js	20.19.4
Commit	cefeef88af6115fffc624a09eb375595d6a5b208
Horizonte	3 años; maíz; 10 ha; 30 sensores
ML	2500 registros sintéticos; entrenamiento/prueba 80/20; búsqueda 5 folds; evaluación 10 folds
Bootstrap	2000 réplicas; nivel de significancia $\alpha = 0.05$

Comandos de reproducción: npx tsx scripts/run-experiment-lca.ts resultados_experimento; py -3.11 scripts/run_experiment_ml.py; py -3.11 scripts/build_experiment_outputs.py.

A.2 Hiperparámetros finales

Modelo	Configuración seleccionada
Random Forest	n_estimators=200; max_depth=30; max_features=log2; min_samples_split=2; min_samples_leaf=1
XGBoost	n_estimators=500; max_depth=4; learning_rate=0.1; subsample=0.8; colsample_bytree=0.8; reg_alpha=0.5; reg_lambda=2.0
SVR	kernel=rbf; C=500; epsilon=0.01; gamma=auto
Stacking	final_estimator Ridge; alpha=100; base estimators RF, XGBoost y SVR
Blending	weights RF=0.4; XGBoost=0.5; SVR=0.1

A.3 Trazabilidad de factores y alcance

El registro de factores incluido en el material suplementario conserva la procedencia declarada para cada factor; la Tabla 1 resume los valores empleados. Los factores del registro de AP-9 están explícitamente marcados como demostrativos. Por tanto, los resultados se interpretan como una evaluación reproducible del comportamiento del motor y de decisiones relativas entre arquitecturas, no como un inventario certificado de una explotación real. No se ejecutó Monte Carlo porque el registro no proporciona distribuciones ni rangos de incertidumbre validados; no se introdujeron distribuciones supuestas.

A.4 Material suplementario entregado

El paquete incluye: 00_reporte_ejecucion.md; 01_configuracion_escenarios.csv; 02_validacion_motor_lca.csv; 03_resultados_arquitecturas.csv; 04_desglose_capas_etapas.csv; 07_analisis_sensibilidad.csv; 08_metricas_modelos.csv; 09_metricas_por_fold.csv; 10_pruebas_estadisticas.csv; 11_importancia_variables.csv; 12_hiperparametros.json; 13_metadatos_reproducibilidad.json; 14_limitaciones.md y 15_verificacion_reproducibilidad.json. Una segunda ejecución con la misma semilla reprodujo los totales LCA y las métricas ML.

A.5 Consideraciones responsables de IA

El conjunto para aprendizaje automático es sintético y no contiene datos personales ni atributos protegidos. El riesgo principal no es la discriminación sobre personas, sino la extrapolación indebida: el modelo aprende relaciones del generador implementado y no debe utilizarse para inferir emisiones agrícolas reales sin calibración externa. La revisión humana verificó los parámetros, las métricas y los resultados exportados.